

Detección de Residuos Reciclables en una Cinta Transportadora con YOLOv8: una Comparación de Políticas de Aumentación

Julia Maldonado, Alejandro Valle, María Gabriela Di Grazia, Byron García
Carrera de Especialización en Inteligencia Artificial (CEIA)
Facultad de Ingeniería, Universidad de Buenos Aires (FIUBA)
Visión por Computadora II — Grupo 6

Abstract—Los centros de acopio reciben residuos mezclados cuya separación manual es lenta y costosa. Este trabajo propone un sistema de visión por computadora que, instalado sobre una cinta transportadora, detecta y clasifica residuos en seis categorías (biodegradable, cartón, vidrio, metal, papel y plástico) para priorizar la extracción de los materiales de mayor valor de reciclaje. Se entrenaron y compararon cuatro configuraciones — dos variantes de YOLOv8 (n y s) bajo dos políticas de aumentación de datos — sobre un conjunto de 10.464 imágenes (dataset Garbage Classification 3, Roboflow). La política de aumentación propuesta, diseñada a partir de un análisis cuantitativo de las carencias del dataset (orientación, iluminación y nitidez), mejoró el mAP@0.5:0.95 en +1,2 puntos (YOLOv8s) y +0,7 puntos (YOLOv8n) frente a la configuración por defecto de Ultralytics, con YOLOv8s + proposed alcanzando 0,650 de mAP@0.5 y 55 FPS en una GPU T4.

Index Terms—detección de objetos, YOLOv8, clasificación de residuos, aumentación de datos, visión por computadora, reciclaje.

I. INTRODUCCIÓN

En ciudades concurridas se genera una gran cantidad de basura mezclada. Separarla manualmente, material por material, es lento y costoso, y gran parte del material reciclable pierde valor comercial por no identificarse y extraerse a tiempo durante el procesamiento. Clasificar directamente en la vía pública, durante la recolección, es poco práctico por las condiciones de iluminación y movimiento; resulta más viable automatizar la clasificación una vez que el residuo llega a un centro de acopio o planta de procesamiento, donde puede pasar por una cinta transportadora bajo condiciones controladas de cámara.

El objetivo de este trabajo es diseñar y evaluar un sistema de detección de objetos basado en deep learning que, sobre una cinta transportadora, identifique en tiempo real la categoría de cada residuo y permita priorizar la extracción de los materiales de mayor valor de reciclaje (por ejemplo, aluminio, PET o cartón), en lugar de requerir una separación exhaustiva del 100% del flujo. El alcance de este trabajo se concentra en el problema de visión por computadora — detección y clasificación de los distintos tipos de residuos — dejando la implementación física del mecanismo de separación (brazo mecánico o aire a presión) como una extensión futura de la aplicación.

Como antecedente de un caso real, Koskinopoulou et al. [1] describen un sistema de categorización basado en visión por computadora para la separación robótica industrial de residuos reciclables, desplegado y evaluado en una planta de procesamiento de residuos real, bajo condiciones industriales exigentes, utilizando un módulo de visión de bajo costo basado en deep learning. En la industria, Recycleye reporta un caso de despliegue en la planta de materiales recuperables (MRF) de re3 en Reading, Reino Unido, con 99% de pureza del material separado frente a 96% en la línea de separación humana de referencia y hasta 55 extracciones por minuto [2]. Ambos antecedentes respaldan la viabilidad de un enfoque de visión por computadora para esta tarea, aunque las cifras de la industria no están auditadas de forma independiente, a diferencia de las métricas reportadas en este trabajo.

II. METODOLOGÍA

A. Conjunto de datos y procesamiento

Se utilizó el dataset público Garbage Classification 3 (v2, formato YOLOv8) de Roboflow [3], con 10.464 imágenes anotadas en seis clases: biodegradable, cardboard, glass, metal, paper y plastic. Previo al entrenamiento se auditó el export crudo para descartar imágenes corruptas y corregir o eliminar anotaciones defectuosas — un paso necesario porque los exports de Roboflow pueden contener errores de etiquetado que de otro modo perjudican el entrenamiento de forma silenciosa. Se re-dividió el dataset en una partición propia 70/20/10 (train/val/test) en lugar de conservar la de Roboflow, que resultaba desbalanceada entre clases y habría invalidado la evaluación por clase. El conjunto de test se mantuvo reservado y sin aumentar hasta la evaluación final.

B. Política de aumentación

Las técnicas de aumentación se eligieron a partir de un análisis cuantitativo del dataset procesado — no de supuestos genéricos — midiendo brillo, nitidez, color y balance de clases. El análisis mostró que al dataset le faltan imágenes oscuras o borrosas, condiciones esperables en video real de una cinta transportadora, y que el desbalance de clases observado se debe a la cantidad de objetos por foto y no a la cantidad de fotos por clase. A partir de esos hallazgos se definieron dos configuraciones (*arms*) para comparar:

`ultralytics_defaults`, la aumentación por defecto de Ultralytics [4] (mosaico, jitter HSV, flip horizontal, traslación y escala), y `proposed`, que añade flip vertical, oscurecimiento (reducción de brillo de hasta -40% con probabilidad 0,3), motion blur y Gaussian blur, para cubrir las carencias medidas de orientación, iluminación y nitidez, implementadas con Albumentations [5]. La aumentación se aplica en forma *online* durante el entrenamiento, a partir de un único archivo de configuración compartido, de modo que todas las corridas usen exactamente la misma política y el conjunto de test nunca se aumenta por accidente.

C. Entrenamiento y evaluación

Se realizó fine-tuning de dos variantes pre-entrenadas de YOLOv8 [4] — YOLOv8n y YOLOv8s — bajo cada una de las dos políticas de aumentación, resultando en cuatro configuraciones entrenadas. Cada modelo se entrenó durante 50 épocas, batch size 16 y semilla fija (42), sobre una GPU T4 (Google Colab). La evaluación se realizó sobre el conjunto de test reservado, reportando mAP@0.5, mAP@0.5:0.95, F1 y latencia de inferencia extremo a extremo (200 imágenes de test, procesadas una por una), medida tanto en GPU T4 como en CPU de notebook (Intel i5-1135G7).

III. RESULTADOS EXPERIMENTALES Y ANÁLISIS

La Tabla I resume las métricas de las cuatro configuraciones sobre el conjunto de test. La política `proposed` superó a `ultralytics_defaults` en ambas arquitecturas: +1,2 puntos de mAP@0.5:0.95 en YOLOv8s y +0,7 puntos en YOLOv8n. La mejora se observó en cinco de las seis clases en ambos modelos, con una única excepción menor en CARDBOARD (-0,008), lo que sugiere que el oscurecimiento y el desenfoque agregados por la política propuesta ayudan de forma consistente sin introducir una regresión relevante.

TABLE I
MÉTRICAS POR MODELO Y RECETA (CONJUNTO DE TEST)

Modelo	Receta	mAP@0.5	mAP@.5:0.95	F1
YOLOv8s	<code>proposed</code>	0.650	0.467	0.650
YOLOv8s	<code>ultralytics_defaults</code>	0.645	0.455	0.646
YOLOv8n	<code>proposed</code>	0.629	0.443	0.625
YOLOv8n	<code>ultralytics_defaults</code>	0.622	0.435	0.617

YOLOv8s superó a YOLOv8n en las seis clases bajo ambas recetas, a cambio de mayor latencia: en GPU T4, YOLOv8s + `proposed` procesó cada imagen en 18,1 ms (55 FPS) frente a 10,2 ms (98 FPS) de YOLOv8n + `proposed`. En CPU (Intel i5-1135G7, pesos `proposed`), YOLOv8n alcanzó 68,9 ms (14,5 FPS) frente a 177,3 ms (5,6 FPS) de YOLOv8s — una diferencia de 2,6× relevante para un despliegue sin GPU dedicada.

El modelo recomendado es YOLOv8s con la política `proposed`, por tener el mejor mAP@0.5:0.95 y F1 del conjunto y correr en tiempo real sobre GPU (55 FPS). Para un despliegue sin GPU se recomienda YOLOv8n +

`proposed` como alternativa, con una caída de 2,4 puntos de mAP@0.5:0.95 a cambio de ser 2,6× más rápido en CPU. Las clases con peor desempeño en ambos modelos son BIODEGRADABLE, CARDBOARD y PAPER (mAP@0.5:0.95 entre 0,36 y 0,43 en YOLOv8s), consistente con la variabilidad visual de esos materiales.

A. Demostración sobre una cinta simulada

Para ilustrar el funcionamiento del sistema sin una cinta física se construyó una simulación: 11 imágenes del conjunto de test (elegidas al azar con semilla fija), cada una reescalada a un cuadrado de 420 px, se deslizan de izquierda a derecha sobre un fondo de banda de 1280×540 px, a 30 FPS durante 20 s (600 cuadros), como si pasaran frente a una cámara fija. El modelo recomendado (YOLOv8s + `proposed`, umbral de confianza 0,25) se ejecuta cuadro por cuadro, igual que lo haría un sistema en línea. La Fig. 1 muestra seis cuadros representativos.

La latencia por cuadro (preprocesado, inferencia y NMS) fue de 22,9 ms en promedio (43,7 FPS) y 13,3 ms en el percentil 95, ejecutando sobre la GPU integrada (backend MPS) de un MacBook Pro. Que el promedio supere al percentil 95 indica que unos pocos cuadros iniciales fueron mucho más lentos (calentamiento del dispositivo); en régimen estable el modelo quedó por encima de los 30 FPS del video simulado.

TABLE II
DETECCIONES POR CLASE EN LA DEMOSTRACIÓN (CONTEO POR CUADRO)

Clase	Detecciones	Confianza media
GLASS	1241	0.616
METAL	746	0.617
PLASTIC	482	0.487
PAPER	188	0.686
BIODEGRADABLE	53	0.554
CARDBOARD	5	0.396

La Tabla II cuenta detecciones *por cuadro*: un mismo objeto aparece en muchos cuadros consecutivos, de modo que la tabla refleja las imágenes que recorrieron la banda y no la cantidad de objetos distintos (para ello haría falta seguimiento, ver Conclusiones). En los cuadros inspeccionados se observaron dos comportamientos. Por un lado, los objetos de apariencia clara se clasifican con confianza alta, por ejemplo las botellas de vidrio verdes (0,81 a 0,89). Por otro, aparecen confusiones que las métricas agregadas de test no hacen visibles: un mismo bidón plástico blanco se etiquetó como PLASTIC (0,66) en un cuadro y como METAL (0,67) en otro; un vaso de papel se etiquetó como PAPER (0,69) y, al entrar por el borde de la banda parcialmente recortado, como METAL (0,65); un frasco de vidrio se etiquetó como METAL; y los restos de aguacate en un recipiente se etiquetaron como GLASS en lugar de BIODEGRADABLE. La clase se vuelve inestable cuando el objeto aparece cortado en el borde del encuadre, un escenario que el test sobre imágenes completas no mide. CARDBOARD casi no se detectó (5 detecciones, confianza media 0,396), coherente con su bajo desempeño en test. Estas observaciones




Fig. 1. Seis cuadros de la demostración sobre la cinta simulada, con las detecciones del modelo YOLOv8s + proposed. Se observan aciertos (botellas de vidrio, vaso de papel) y confusiones entre clases, en particular METAL.

son cualitativas y se basan en 11 imágenes distintas, por lo que no sustituyen la evaluación cuantitativa de la Tabla I.

Limitaciones: cada modelo y receta se entrenó una única vez, por lo que las diferencias reportadas no fueron sometidas a un test de significancia estadística. De las cuatro recetas definidas en la política de aumentación, solo dos (*ultralytics_defaults* y *proposed*) fueron efectivamente entrenadas; *no_augmentation* y *proposed_low_saturation* quedan como trabajo futuro. Las matrices de confusión se calcularon sobre el conjunto de validación, no sobre el de test. Además, el dataset utilizado, aunque realista, no replica completamente el nivel de desorden visual (objetos superpuestos, oclusiones parciales) que literatura especializada documenta en video real de cintas transportadoras [6]; validar el modelo recomendado contra imágenes propias de la banda, más cercanas a ese escenario, queda como un paso natural antes de un despliegue productivo.

IV. CONCLUSIONES

- 1) Una política de aumentación diseñada a partir de carencias medidas cuantitativamente en el dataset (orientación, iluminación, nitidez) mejora el $mAP@0.5:0.95$ de forma consistente frente a los valores por defecto de Ultralytics, en ambas arquitecturas evaluadas, sin necesidad de recolectar más datos.
- 2) YOLOv8s ofrece mejor precisión que YOLOv8n en las seis clases bajo ambas recetas, pero a un costo de latencia relevante en CPU ($2.6\times$ más lento que YOLOv8n), por lo que la elección entre ambos depende directamente del hardware de despliegue disponible en el centro de acopio.
- 3) Re-dividir el dataset en lugar de usar la partición original de Roboflow fue necesario para obtener una evaluación por clase confiable, dado el desbalance detectado en la partición original.

- 4) Las clases BIODEGRADABLE, CARDBOARD y PAPER concentran el menor desempeño del sistema, lo que sugiere que la ambigüedad visual entre materiales orgánicos y de fibra es el cuello de botella principal a resolver en una futura iteración, más que la arquitectura del detector en sí.
- 5) La demostración sobre una cinta simulada corrió a 43,7 FPS en una GPU integrada (MPS), por encima de los 30 FPS del video, pero mostró confusiones que el test no revela, sobre todo METAL frente a PLASTIC, PAPER y GLASS, y clases inestables cuando el objeto queda cortado en el borde del encuadre. Esto refuerza que el siguiente paso es validar con imágenes propias de la banda y con objetos parcialmente visibles.
- 6) Como trabajo futuro, la arquitectura puede extenderse incorporando seguimiento de objetos (*tracking*) para evitar contar el mismo residuo dos veces en video, y evaluando directamente la implementación física del mecanismo de separación, que quedó fuera del alcance de este trabajo.

REFERENCES

- [1] M. Koskinopoulou, F. Raptopoulos, G. Papadopoulos, N. Mavrakis, and M. Maniadakis, "Robotic waste sorting technology: Toward a vision-based categorization system for the industrial robotic separation of recyclable waste," *IEEE Robotics & Automation Magazine*, vol. 28, no. 2, pp. 50–60, 2021.
- [2] Recycle, "re3 achieves 99% purity with AI picking robot." <https://www.letsrecycle.com/news/re3-achieves-99-purity-with-ai-picking-robot/>, 2022. Accessed: 2026-10-08.
- [3] Material Identification, "Garbage classification 3." <https://universe.roboflow.com/material-identification/garbage-classification-3>, 2024. Roboflow Universe. Accessed: 2026-10-08.
- [4] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLOv8." <https://github.com/ultralytics/ultralytics>, 2023.
- [5] A. Buslaev, V. I. Iglovikov, E. Khvedchenya, A. Parinov, M. Druzhinin, and A. A. Kalinin, "Albumentations: Fast and flexible image augmentations," *Information*, vol. 11, no. 2, p. 125, 2020.
- [6] D. Bashkirova, M. Abdelfattah, Z. Zhu, J. Akl, F. Alladkani, P. Hu, V. Ablavsky, B. Calli, S. A. Bargal, and K. Saenko, "Zerowaste dataset: Towards deformable object segmentation in cluttered scenes," in *Pro-*

ceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022.