VISIÓN POR COMPUTADORA II · GRUPO 6

Residuos reciclables en una cinta transportadora

Detección con YOLOv8 y una política de aumentación basada en datos

BIODEGRADABLE CARDBOARD GLASS METAL PAPER PLASTIC

Julia Maldonado · Alejandro Valle · María Gabriela Di Grazia · Byron García

Especialización en Inteligencia Artificial (CEIA) · FIUBA

01 · PROBLEMA

Separar residuos a mano es lento y costoso

Hoy

Los residuos llegan mezclados al centro de acopio y se separan a mano. Parte del material reciclable pierde valor por no extraerse a tiempo.

Propuesta

Una cámara sobre la cinta y un detector que identifica la categoría de cada residuo, para priorizar los materiales de mayor valor.

Alcance

Solo la visión: detectar y clasificar en 6 clases. El mecanismo que separa (brazo o aire a presión) queda como trabajo futuro.

> CASOS REALES
>
> **Koskinopoulou et al. (IEEE RAM, 2021):** visión para separación robótica, desplegada en una planta real de residuos.
>
> **Recycleye en re3 (Reino Unido, 2022):** 99 % de pureza frente a 96 % de la línea humana (cifra de la industria, no auditada).

02 · ENFOQUE

Un pipeline reproducible de punta a punta

01 →

Datos crudos

Roboflow · 10.464 imágenes · 6 clases

02 →

Procesamiento

Auditoría de etiquetas y partición propia 70/20/10

03 →

Aumentación

Política derivada de mediciones, en un archivo versionado

04 →

Entrenamiento

Fine-tuning de YOLOv8n y YOLOv8s, evaluación en test

05

Demo

Cinta simulada, detección frame por frame

Test reservado

El 10 % de test no se aumenta ni se mira hasta la evaluación final.

Aumentación online

Solo sobre train, desde un único archivo de configuración: todas las corridas usan la misma política.

03 · DATOS

10.464 imágenes, 6 clases, partición propia



BIODEGRADABLE



CARDBOARD



GLASS



METAL



PAPER



PLASTIC

Partición 70 / 20 / 10

La de Roboflow separaba clases: su test no tenía GLASS. Re-dividimos de forma estratificada.

Desbalance en las cajas

BIODEGRADABLE: 61 % de las cajas con 22 % de las imágenes (~20 objetos por foto).

Auditoría del export

Se descartaron imágenes corruptas y se corrigieron o eliminaron anotaciones defectuosas.

Primero medimos qué le falta al dataset

5,3 %

de las imágenes son oscuras (brillo medio < 100), frente a 31,7 % muy claras.

→ oscurecimiento

12,7 %

de las imágenes son poco nítidas: casi todo está bien enfocado.

→ motion blur y desenfoque

~70 %

de cada split ya fue volteado o rotado por Roboflow; el resto está en orientación natural.

→ flip vertical

2×

el azar: 12 estadísticas globales de la foto adivinan la clase (46–55 % frente a 25 %).

→ mosaico y jitter de color

Dos recetas: la base y la propuesta



`Original`

imagen de train



`Flip vertical`

más orientaciones



`Oscurecimiento (máx.)`

oscuras: 4,9 % → 11,6 %



`Desenfoque (máx.)`

poco nítidas: 14 % → 26 %

`ultralytics_defaults · base`

- Mosaico y jitter HSV
- Flip horizontal, traslación y escala
- Blur, MedianBlur, ToGray y CLAHE (p = 0,01)

`proposed · propuesta`

- Base + flip vertical (p = 0,5)
- Oscurecimiento: brillo −0,4 (p = 0,3)
- Motion blur (p = 0,15) y gaussiano (p = 0,1)
- Reemplaza las 4 transformaciones integradas

proposed supera a la base en ambos modelos

Fine-tuning · 50 épocas · batch 16 · semilla 42 · GPU T4 · test: 1.045 imágenes

Modelo	Receta	mAP@0.5	mAP@.5:.95	F1
YOLOv8s	proposed	0,650	0,467	0,650
YOLOv8s	ultralytics_defaults	0,645	0,455	0,646
YOLOv8n	proposed	0,629	0,443	0,625
YOLOv8n	ultralytics_defaults	0,622	0,435	0,617

+1,2
puntos de mAP@.5:.95 en YOLOv8s

+0,7
puntos de mAP@.5:.95 en YOLOv8n

> También en validación (+1,4 y +1,1) y en 5 de 6 clases; la única baja es CARDBOARD (−0,8 puntos).
> **Una corrida por receta:** dirección consistente, todavía sin test de significancia.

Recomendado: YOLOv8s + proposed

Modelo	GPU T4	CPU (i5-1135G7)
YOLOv8s	18,1 ms · 55 FPS	177,3 ms · 5,6 FPS
YOLOv8n	10,2 ms · 98 FPS	68,9 ms · 14,5 FPS

Latencia extremo a extremo por imagen (lectura, preprocesado, inferencia y NMS): 200 imágenes de test, una por una, pesos proposed.

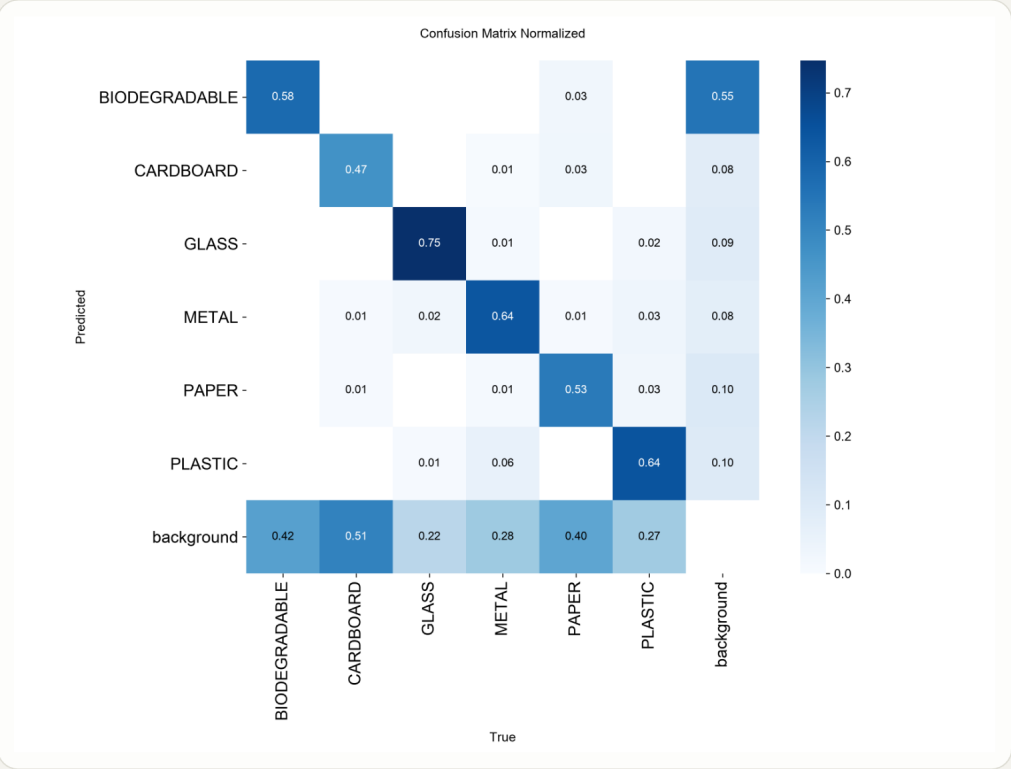
Con GPU

YOLOv8s: el mejor mAP@.5:.95 (0,467) y F1 (0,650), en tiempo real a 55 FPS.

Sin GPU

YOLOv8n: 2,6× más rápido en CPU, a cambio de 2,5 puntos de mAP@.5:.95.

El problema es no detectar, no confundir



Clase	Correcto	Otra clase	No detectado
CARDBOARD	47 %	2 %	51 %
BIODEGRADABLE	58 %	0,4 %	42 %
PAPER	53 %	7 %	40 %
METAL	64 %	8 %	28 %
PLASTIC	64 %	9 %	27 %
GLASS	75 %	4 %	22 %

Mayor confusión entre clases: **METAL → PLASTIC, 5,5 %**.

BIODEGRADABLE genera el 55 % de las detecciones falsas sobre el fondo y tiene el 60 % de las cajas de test.

06 · DEMO

Simulamos la cinta, sin hardware

01 →

Imágenes de test

11 imágenes que el modelo nunca vio al entrenar.

02 →

Deslizan sobre la banda

De izquierda a derecha, 30 FPS durante 20 s: 600 frames de 1280×540.

03 →

YOLOv8s + proposed

Detección frame por frame, con umbral de confianza 0,25.

04

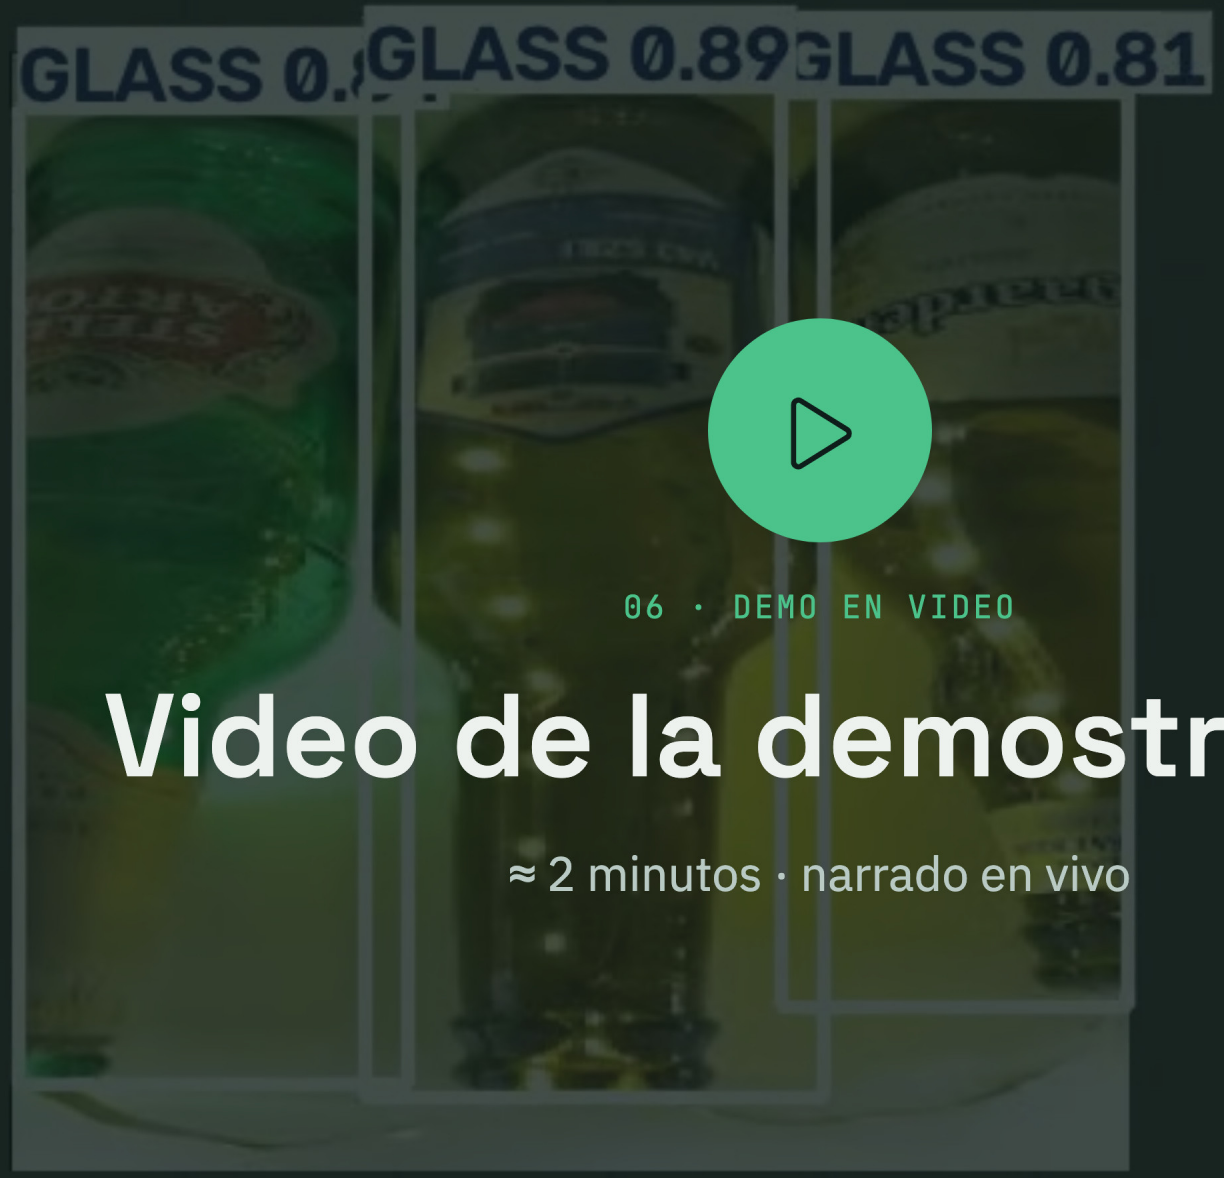
Detecciones y latencia

Clase y confianza por objeto, y el tiempo de cada frame.

157 FPS

6,35 ms por frame en promedio

En una GPU integrada (MPS), tras 10 frames de calentamiento. Mediana 6,45 ms y p95 7,09 ms: muy por encima de los 30 FPS del video.

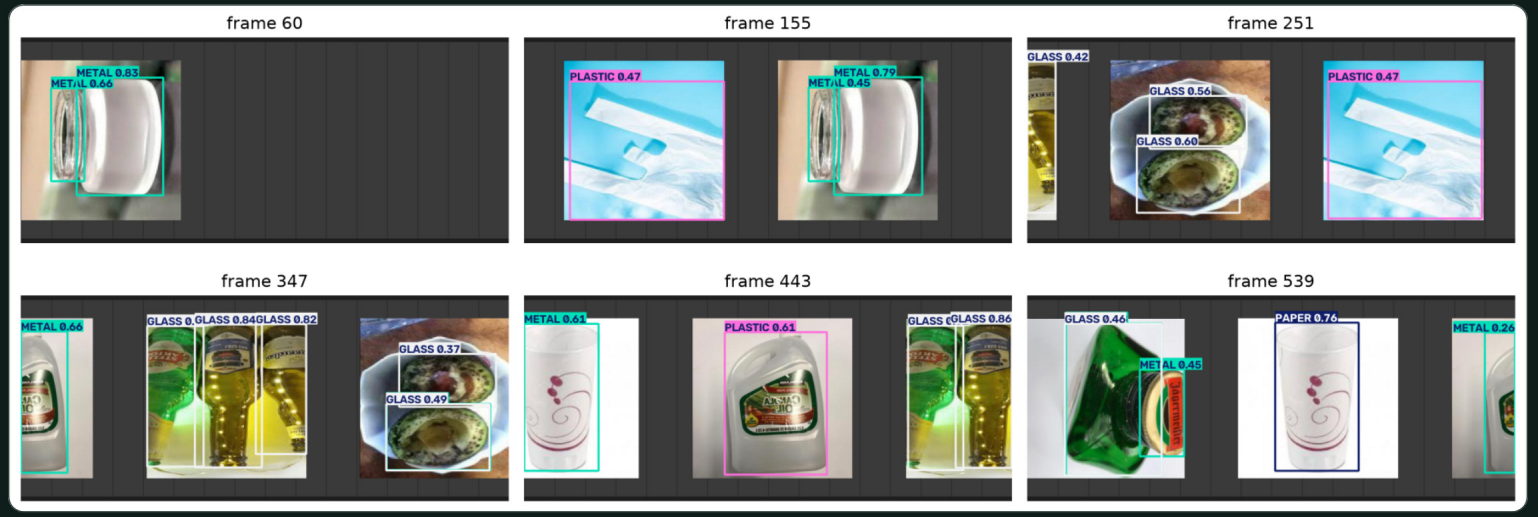


06 · DEMO EN VIDEO

Video de la demostración

≈ 2 minutos · narrado en vivo

Qué mostró la demo



Aciertos

Botellas de vidrio erguidas: GLASS con 0,82 a 0,86.

Inestable en el borde

Enteros, el bidón es PLASTIC y el vaso PAPER; cortados en el borde, ambos METAL.

Casi invisible

CARDBOARD: 5 detecciones en 600 frames, coherente con su 51 % sin detectar.

Limitaciones y próximos pasos

Limitaciones

- Una corrida por receta: sin test de significancia
- Las recetas difieren en varias transformaciones y en la versión de Ultralytics
- Solo 2 de las 4 recetas definidas se entrenaron
- Demo con 11 imágenes, contando detecciones por frame
- El dataset es más ordenado que una cinta real

Próximos pasos

- Validar con imágenes de una banda real, con objetos superpuestos y parciales
- Mejorar el recall de CARDBOARD, BIODEGRADABLE y PAPER
- Repetir corridas con varias semillas y entrenar las recetas restantes
- Tracking para no contar dos veces el mismo residuo
- Implementar el mecanismo físico de separación

07 · CIERRE

Conclusiones

1. La aumentación basada en carencias medidas superó a la base en ambos modelos (+1,2 y +0,7 puntos de mAP@.5:.95), en validación y en test.
2. YOLOv8s + proposed es el más preciso y corre en tiempo real con GPU; YOLOv8n es la alternativa sin GPU (2,6× más rápido en CPU).
3. Las clases débiles fallan por no ser detectadas (40–51 %), no por confundirse: el próximo paso es mejorar el recall.
4. La demo corre a 157 FPS y muestra clases inestables en objetos cortados: hay que validar con una banda real.

Gracias. ¿Preguntas?

github.com/AlejandroValle99/VPC2_TP